EPSI Grenoble

Certification RNCP35584 — Niveau 7

MSPR TPRE813 - Big data et Analyse de données

Electio Analytics Lyon

Dossier de Synthèse

Analyse et prédiction des tendances électorales
à partir de données socio-économiques publiques

Projet MSPR — Electio Analytics
Ville de Lyon — 9 arrondissements
Modèles : Random Forest & Logistic Regression

Groupe :

- CHAOUSARI Khaoula
- LINGENU NDALA Adonnay
- HADDAD Rayane

Année universitaire : 2025–2026

Date de rendu : 14 Avril 2026

Table des matières

1 Contexte et objectifs du projet **1**
1.1 Présentation d'Electio-Analytics 1
1.2 Besoin stratégique 1
1.3 Objectif du POC 1
1.4 Livrables attendus 2
1.5 Méthodologie de travail 2

2 Périmètre géographique et justification **2**
2.1 Choix de Lyon 2
2.2 Découpage géographique 3
2.3 Scrutins analysés 3

3 Sources de données et stratégie de collecte **3**
3.1 Stratégie de collecte 3
3.2 Sources utilisées 4

4 Modèle Conceptuel de Données **4**
4.1 Présentation du modèle 4
4.2 Cardinalités principales 5
4.3 Schéma du MCD 5
4.4 Lien avec le modèle décisionnel 5

5 Architecture technique et pipeline ETL **5**
5.1 Architecture décisionnelle 3 couches 5
5.2 Vue d'ensemble du flux de traitement 6
5.3 Traçabilité et reproductibilité 8
5.3.1 Colonnes de contrôle qualité 8
5.3.2 Formalisation complémentaire du pipeline en Python 8
5.4 Industrialisation cible 9

6 Chronologie des transformations **9**

7 Qualité des données et nettoyage **10**
7.1 Cadre de contrôle qualité 10
7.2 Résultats du Data Cleansing 10

8 Modèles de Machine Learning **10**
8.1 Approche méthodologique 10
8.2 Benchmark des modèles testés 11
8.2.1 Justification des modèles non retenus 11

8.3 Justification du choix des algorithmes retenus 11
8.3.1 Random Forest — Prédiction de la participation 11
8.3.2 Régression Logistique — Prédiction du bloc gagnant 12
8.4 Comparaison avec la baseline 13
8.5 Modèle 1 — Prédiction de la participation 13
8.6 Modèle 2 — Prédiction du bloc gagnant 13
8.7 Feature Importance 14
8.8 Limites méthodologiques de l'évaluation 14

9 Résultats et prédictions 2026 14
9.1 Prédictions par arrondissement 14

10 Visualisations et restitution Power BI 15
10.1 Présentation du dashboard 15
10.2 Visualisations 16
10.2.1 Visual 1 — Résultats électoraux par arrondissement 2020 (Tableau) 17
10.2.2 Visual 2 — Blocs gagnants 2020 (Donut chart) 17
10.2.3 Visual 3 — Évolution de la participation 2014 → 2020 (Area chart) 18
10.2.4 Visual 4 — Prédictions 2026 Modèle Logistic Regression (Barres groupées) 19
10.2.5 Visual 5 — Indice précarité & dynamisme éco (Radar chart) . . 20
10.2.6 Visual 6 — Corrélation socio-économique : cadres % vs revenu médian (Scatter chart) 21

11 Validation sur données réelles 21
11.1 Comparaison prédictions vs résultats réels 2026 22
11.2 Métriques de validation 22

12 Conformité RGPD et sécurité 23

13 Réponses aux indicateurs d'analyse 23
13.1 Variable la plus corrélée aux résultats électoraux 23
13.2 Interprétation du degré de précision 23

14 Limites et recommandations 24
14.1 Limites identifiées 24
14.2 Recommandations pour la production 24

15 Conclusion 24
15.1 Synthèse de conformité au cahier des charges 24
15.2 Valeur ajoutée du POC 25

Annexes 26

1 Contexte et objectifs du projet

1.1 Présentation d'Electio-Analytics

Electio-Analytics est une startup fondée en 2017 par Jean-Édouard de la Motte-Rouge, spécialisée dans le conseil stratégique pour les campagnes électorales. Son ambition est d'apporter à ses clients — candidats, partis politiques et cabinets de conseil — des analyses prospectives précises à partir de données publiques. L'équipe se compose de :

- Un expert en analyse politique (doctorat en science politique, expérience terrain sur plusieurs scrutins nationaux),
- Un business developer (master en marketing digital, réseau de contacts auprès de partis et d'organismes de financement),
- Une assistante (formation en gestion administrative, coordination et suivi du projet).

1.2 Besoin stratégique

Electio-Analytics souhaite mettre en place une capacité de prévision des tendances électorales à moyen terme (1 à 3 ans) à partir d'indicateurs socio-économiques objectivables. Ce dispositif lui donnerait un avantage concurrentiel décisif dans son activité de conseil électoral.

1.3 Objectif du POC

Ce projet constitue une **Preuve de Concept (POC)** visant à :

- Valider la faisabilité d'une chaîne décisionnelle complète : collecte → traitement → modélisation → restitution,
- Démontrer l'existence d'un signal exploitable entre indicateurs socio-économiques et résultats électoraux,
- Concevoir et tester un premier modèle supervisé capable d'identifier des tendances électorales à partir d'indicateurs territoriaux,
- Préparer les conditions d'un passage à l'échelle nationale.

Important : Le présent POC doit être compris comme un démonstrateur fonctionnel et méthodologique, non comme un produit prédictif stabilisé à l'échelle nationale. L'objectif n'est pas de revendiquer une généralisation statistique nationale à ce stade, mais de valider une architecture BI/ML reproductible, explicable et industrialisable.

1.4 Livrables attendus

Table 1 – Livrables du projet

N°	Livrable	Format	Statut
1	Dossier de synthèse	PDF/DOCX	✓ Ce document
2	Jeu de données nettoyé et normalisé	CSV	✓ `elections_ml_ready.csv`
3	Pipeline ETL traçable	Dataiku Flow	✓ Flow documenté et rejouable
4	Support de soutenance	PPTX	✓ MSPR.pptx

1.5 Méthodologie de travail

L'organisation du projet a reposé sur trois piliers complémentaires.

Dépôt Git collaboratif. L'ensemble des productions — scripts ETL, notebooks d'analyse, fichiers de configuration Dataiku et versions successives du présent document — a été versionné sur un dépôt GitHub commun :

https://github.com/l3miage-haddaray/MSPR-Big-Data-Groupe-KRA

Chaque membre de l'équipe contribuait via des commits réguliers, permettant une traçabilité complète de l'avancement et un retour en arrière en cas de besoin.

Coordination via Discord. Les échanges inter-séances ont été assurés par un serveur Discord dédié au projet. Ce canal a permis de partager rapidement les résultats intermédiaires, de débloquer les points techniques et de synchroniser les décisions entre les membres de l'équipe sans attendre les séances en présentiel.

Séances MSPR dédiées. Le projet a également bénéficié de séances de travail encadrées spécifiquement allouées au MSPR, au cours desquelles l'équipe a pu avancer collectivement sur les étapes clés : conception du pipeline ETL, choix des modèles, interprétation des résultats et rédaction du présent dossier.

2 Périmètre géographique et justification

2.1 Choix de Lyon

Le périmètre retenu est la ville de Lyon avec ses 9 arrondissements. Ce choix répond à plusieurs critères de pertinence pour un POC.

Table 2 – Justification du choix de Lyon

Critère	Justification
Diversité sociologique	Fort contraste entre arrondissements (du 6e très aisé au 8e populaire)
Alternance politique	Basculements observés entre 2014 et 2020, notamment le 5e passé aux écologistes
Disponibilité des données	INSEE publie des données détaillées par arrondissement (codes 69381 à 69389)
Taille maîtrisable	9 arrondissements permettent un POC lisible et entièrement explicable
Représentativité	3e ville de France, représentative des grandes métropoles françaises

2.2 Découpage géographique

Table 3 – Les 9 arrondissements de Lyon — Périmètre du POC

Code INSEE	Arrondissement	Population (2022)	Profil sociologique
69381	Lyon 1er	30 643	Centre historique, mixte
69382	Lyon 2e	31 531	Affaires, aisé
69383	Lyon 3e	104 279	Résidentiel, diversifié
69384	Lyon 4e	36 316	Croix-Rousse, bobo
69385	Lyon 5e	49 460	Vieux Lyon, mixte
69386	Lyon 6e	52 789	Très aisé, cadres
69387	Lyon 7e	82 896	Universitaire, jeune
69388	Lyon 8e	86 287	Populaire, diversifié
69389	Lyon 9e	54 215	Populaire, HLM

2.3 Scrutins analysés

Nous avons analysé les élections municipales de **2014 et 2020** (second tour). Ces deux scrutins permettent d'observer les évolutions électorales sur une période de 6 ans et de disposer d'un historique cohérent pour construire un premier jeu d'apprentissage.

Limite du périmètre : Ce choix garantit la traçabilité et la lisibilité des résultats, mais implique une limite méthodologique en matière de volume d'apprentissage. Le périmètre lyonnais doit être compris comme un terrain d'expérimentation contrôlé, non comme une base suffisante pour une généralisation statistique nationale.

3 Sources de données et stratégie de collecte

3.1 Stratégie de collecte

Nous avons privilégié des données publiques ouvertes, institutionnelles et documentées, afin d'assurer la traçabilité du POC et la réutilisabilité des traitements. La

stratégie suit le principe de **triangulation des sources**.

Les sources ont été retenues selon quatre critères : officialité, granularité géographique (arrondissement), compatibilité temporelle, et réutilisabilité légale (licence ouverte).

3.2 Sources utilisées

Table 4 – Sources de données du projet

Catégorie	Source	Année	URL
Élections	data.gouv.fr	2014, 2020	data.gouv.fr/fr/pages/donnees-des-elections
Population	INSEE RP	2022	insee.fr/fr/statistiques/2011101
Revenus	INSEE Filosofi	2021	insee.fr/fr/statistiques/2011101
Emploi	INSEE RP	2022	insee.fr/fr/statistiques/2011101
Entreprises	INSEE SIDE	2022	insee.fr/fr/statistiques/8287130
Délinquance	Ministère Intérieur	2022	data.gouv.fr/fr/datasets/bases-statistiques-delinquance
Associations	RNA	2022	data.gouv.fr/fr/datasets/repertoire-national-des-associations

4 Modèle Conceptuel de Données

4.1 Présentation du modèle

Le modèle conceptuel de données retenu structure les principales informations manipulées dans le projet autour de l'unité territoriale de base : l'arrondissement de Lyon.

Il met en relation :

— les **arrondissements**,

— les **élections**,

— les **résultats électoraux**,

— les **indicateurs socio-économiques**,

— les **indicateurs de sécurité**,

— les **indicateurs associatifs**,

— les **indicateurs économiques**,

— ainsi que les **variables dérivées utilisées pour le machine learning**.

L'entité `ARRONDISSEMENT` constitue le point central du modèle, car l'ensemble des indicateurs territoriaux y sont rattachés. L'association `RESULTAT_ELECTORAL` relie les arrondissements aux scrutins étudiés via l'entité `ELECTION`, et porte les principales mesures observées : inscrits, votants, participation, abstention, bloc gagnant et score du bloc gagnant.

4.2 Cardinalités principales

Les relations du modèle peuvent être résumées comme suit :

— un `ARRONDISSEMENT` peut être associé à plusieurs `RESULTAT_ELECTORAL` ;

— une `ELECTION` concerne plusieurs `RESULTAT_ELECTORAL` ;

— chaque `ARRONDISSEMENT` possède un unique profil dans les tables `INDICATEUR_SOCIOECO`, `INDICATEUR_SECURITE`, `INDICATEUR_ASSOCIATIONS`, `INDICATEUR_ECONOMIE` et `FEATURES_ML`.

4.3 Schéma du MCD

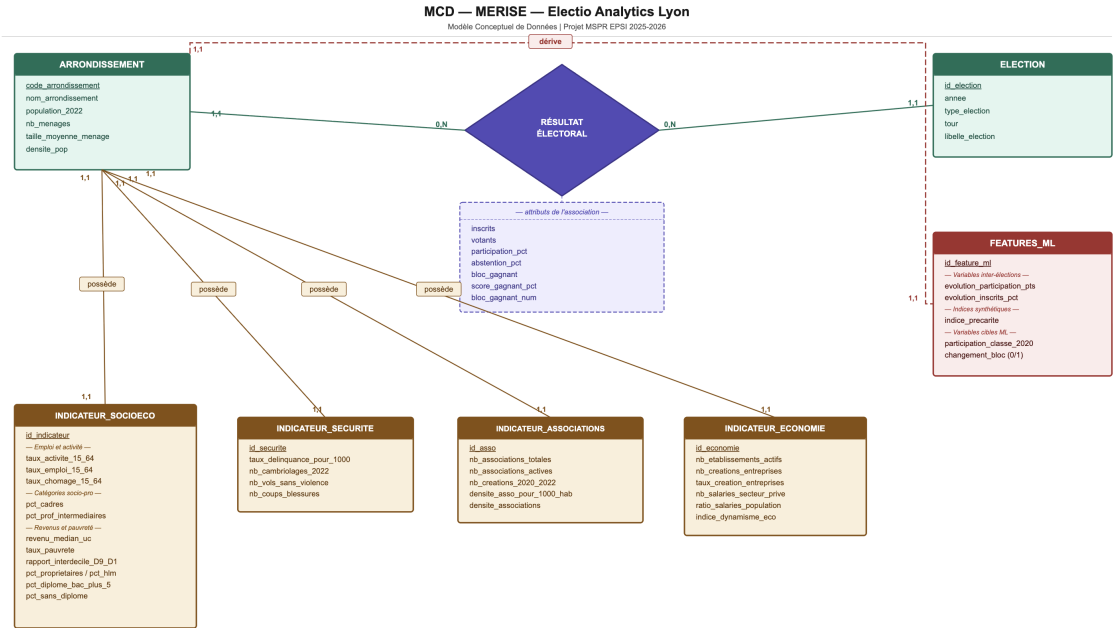

FIGURE 1 – Modèle Conceptuel de Données du projet Electio Analytics Lyon

4.4 Lien avec le modèle décisionnel

Ce modèle conceptuel sert de base à l'organisation logique des données dans le projet. Pour les besoins de l'analyse décisionnelle et de la modélisation, il est ensuite décliné dans une logique plus analytique, proche d'un **modèle en étoile**, afin de faciliter les jointures, les agrégations et la préparation du dataset final `elections_ml_ready.csv`.

5 Architecture technique et pipeline ETL

5.1 Architecture décisionnelle 3 couches

L'architecture retenue repose sur trois couches décisionnelles complémentaires : collecte, transformation/stockage et restitution. Cette structuration en couches est un standard de l'ingénierie décisionnelle (architecture *Lambda* simplifiée), garantissant la

séparation des responsabilités et facilitant la maintenance ou l'évolution de chaque composant indépendamment.

Table 5 – Architecture 3 couches du système décisionnel

Couche	Fonction	Technologies utilisées
Couche 1		
Collecte	Ingestion des données brutes	CSV institutionnels, API REST data.gouv.fr, Dataiku Import
Couche 2		
Stockage & Modélisation	Nettoyage, transformation, stockage structuré	Dataiku Prepare, schéma en étoile, contrôles qualité
Couche 3		
Restitution	Visualisation, analyse et prédiction	Dataiku Charts, Dashboard, ML Lab, exports CSV

5.2 Vue d'ensemble du flux de traitement

Le pipeline suit une logique séquentielle de type **ingestion** → **contrôle** → **transformation** → **enrichissement** → **modélisation** → **restitution**. Cette structuration garantit la reproductibilité des traitements et permet d'identifier clairement les points de contrôle qualité à chaque étape.

$$\texttt{dataset_ml_enrichi_lyon} \xrightarrow{\text{nettoyage + contrôle}} \texttt{elections_validated} \xrightarrow{\text{feature engineering}} \texttt{elections_ml_ready} \xrightarrow{\text{ML}} \texttt{prédictions_2026}$$

Le flow Dataiku ci-dessous illustre visuellement l'ensemble de ce pipeline tel qu'implémenté dans notre projet `ELECTIO_ANALYTICS_LYON` :

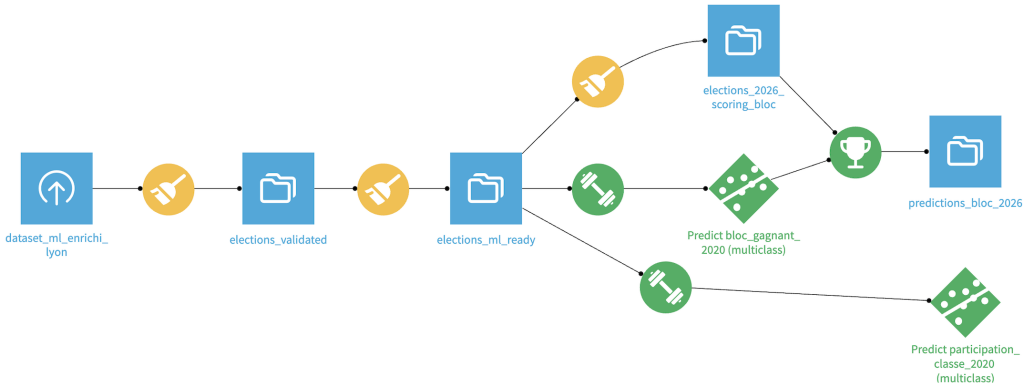

FIGURE 2 – Flow Dataiku DSS — Pipeline ETL complet du projet Electio Analytics Lyon

Lecture du flow (Figure 2) :

— **dataset_ml_enrichi_lyon** (dataset source) : point d'entrée du pipeline, jeu de données brut issu de la fusion multi-sources après collecte initiale.

— **Recettes de préparation** (Prepare recipe) : deux recettes Dataiku successives appliquent le nettoyage, la normalisation et le feature engineering pour produire `elections_validated` puis `elections_ml_ready`.

— **elections_validated** et **elections_ml_ready** (datasets intermédiaires persistés) : chaque étape de transformation produit un dataset versionné, garantissant la traçabilité et le rejeu partiel du pipeline.

— **Predict bloc_gagnant_2020** et **Predict participation_classe_2020** (Lab ML — tâches de classification multiclasse) : deux modèles supervisés entraînés indépendamment sur `elections_ml_ready`.

— **Modèles déployés** (Saved model) : versions actives publiées dans Dataiku, prêtes au scoring sur de nouvelles données.

— **Modèle champion** (Best model) : la Régression Logistique est retenue comme modèle final après benchmark sur le critère ROC AUC.

— **elections_2026_scoring_bloc** et **predictions_bloc_2026** (datasets de sortie) : résultats du scoring 2026 par arrondissement, exports finaux du pipeline.

Architecture en deux branches ML : Le pipeline se divise en deux branches parallèles à partir de `elections_ml_ready` — une pour la prédiction du bloc gagnant (`bloc_gagnant_2020`), l'autre pour la prédiction de la participation (`participation_classe_2020`). Cette séparation permet d'entraîner et d'évaluer chaque modèle indépendamment, tout en partageant le même dataset source nettoyé.

5.3 Traçabilité et reproductibilité

Chaque transformation appliquée dans Dataiku est traçable dans le flow et peut être **rejouée intégralement** à partir des sources brutes. Cette traçabilité constitue un élément clé de reproductibilité, notamment dans la perspective d'un audit méthodologique ou d'un passage à l'échelle nationale.

5.3.1 Colonnes de contrôle qualité

Trois colonnes de contrôle ont été ajoutées au dataset pour tracer la qualité à chaque étape du pipeline :

— `controle_cle_ok` : vérifie l'intégrité des clés primaires (`code_arrondissement`),

— `controle_qualite_pct` : pourcentage de champs valides par observation,

— `controle_dataset_ok` : flag binaire de validation globale de la ligne.

5.3.2 Formalisation complémentaire du pipeline en Python

En complément du flow visuel implémenté dans Dataiku DSS, un script Python documenté a été réalisé afin de formaliser la logique ETL du projet de manière explicite et rejouable.

Ce script reproduit les principales étapes du pipeline :

— chargement des jeux de données consolidés issus des sources institutionnelles,

— vérification des clés géographiques,

— jointure multi-sources,

— création de variables dérivées,

— contrôles qualité,

— export du dataset analytique final.

L'intérêt de cette double implémentation est méthodologique. Dataiku DSS apporte la lisibilité opérationnelle et la traçabilité visuelle du pipeline, tandis que Python explicite de manière détaillée la logique de transformation, de contrôle et de structuration des données.

Dans le cadre du POC, les valeurs issues des sources institutionnelles ont été instanciées dans le script sous forme de *DataFrames* afin de garantir une exécution stable

sans dépendance réseau. Ce choix relève d'une logique de démonstrateur académique et ne correspond pas à une architecture de production connectée directement à des fichiers bruts ou à des API externes.

5.4 Industrialisation cible

Bien que le périmètre expérimental soit volontairement restreint à 9 arrondissements, l'architecture retenue a été pensée pour être **transposable à grande échelle**, jusqu'à une extension nationale par commune (36 000 entités).

Table 6 – Comparaison POC actuel vs architecture de production cible

Dimension	POC actuel	Production cible
Périmètre	9 arrondissements lyonnais	36 000 communes françaises
Volume	9 lignes × 55 colonnes	Plusieurs millions de lignes
Stockage	CSV / Dataiku natif	Parquet / Delta Lake
Orchestration	Manuelle (rejeu Dataiku)	Planifiée et automatisée
Paradigme	ETL	ELT
Mise à jour	Manuelle post-scrutin	Batch périodique

En phase de production, ce pipeline pourrait être adapté à une logique **ELT** s'appuyant sur un stockage colonne de type Parquet/Delta et une orchestration planifiée des mises à jour des sources. Le POC présenté ici en constitue la version fonctionnelle simplifiée et démontre la validité de l'approche avant tout investissement infrastructure.

6 Chronologie des transformations

Table 7 – Séquence complète des transformations

Étape	Action	Dataset produit
1	Collecte des résultats électoraux 2014 et 2020	`resultats_electoraux_brut`
2	Collecte des indicateurs territoriaux INSEE	`insee_socioeco_brut`
3	Harmonisation des clés (codes arrondissements)	`resultats_harmonises`
4	Jointure et consolidation des sources	`dataset_consolide`
5	Contrôle qualité (missing, doublons, types)	`elections_validated`
6	Création des indices composites	`elections_enrichi`
7	Préparation dataset ML (sélection features)	`elections_ml_ready`
8	Entraînement et benchmark des modèles	Modèles ML Lab
9	Scoring des prédictions 2026	`predictions_bloc_2026`
10	Restitution dashboard et exports	Dashboard + CSV

7 Qualité des données et nettoyage

7.1 Cadre de contrôle qualité

La qualité des données a été évaluée selon quatre dimensions : complétude, unicité, cohérence et conformité de format.

7.2 Résultats du Data Cleansing

Table 8 – Bilan du contrôle qualité

Dimension	Contrôle	Résultat	Action
Complétude	Valeurs manquantes (NULL)	Aucune valeur manquante sur les colonnes retenues	Aucune
Unicité	Doublons (clé primaire)	0 doublon détecté	Aucune
Conformité	Types de données	Conformes aux spécifications	Casting auto
Cohérence	Plages de valeurs	Pourcentages dans [0–100]	Validation règles
Cohérence	Inter-sources	Population INSEE ≈ Inscrits électoraux	Vérif. croisée
Robustesse	Outliers statistiques	Aucun outlier aberrant	Analyse IQR

Résultat : Sur le périmètre du POC, l'ensemble des observations conservées satisfait les contrôles définis, sans anomalie bloquante détectée sur les variables utilisées pour la modélisation.

8 Modèles de Machine Learning

8.1 Approche méthodologique

L'apprentissage supervisé est une branche du machine learning où un algorithme apprend à partir d'exemples étiquetés. Le processus se déroule en 3 étapes :

1. **Entraînement :** le modèle analyse des données historiques où la réponse (cible) est connue,
2. **Validation :** le modèle est testé sur des données qu'il n'a pas vues pour mesurer sa capacité de généralisation,
3. **Prédiction :** une fois validé, le modèle prédit sur de nouvelles données.

Dans notre cas : nous avons entraîné le modèle sur les résultats **2014–2020** (données étiquetées) pour prédire **2026** (données non étiquetées).

8.2 Benchmark des modèles testés

Table 9 – Comparaison des algorithmes testés

Modèle	Avantages	Limites	Usage testé	Décision
Decision Tree	Interprétable, règles explicites	Instable sur petit volume	Bloc gagnant	Non retenu
Random Forest	Robuste, importance variables	Moins lisible métier	Participation	✓ Retenu
Logistic Regression	Simple, multiclass, stable	Sensible qualité variables	Bloc gagnant	✓ Retenu
KNN	Intuitif, local	Peu robuste faible volume	Classification	Non retenu

8.2.1 Justification des modèles non retenus

Deux algorithmes testés ont été écartés pour des raisons structurelles incompatibles avec les contraintes du projet.

Decision Tree — Non retenu. Bien que le Decision Tree offre une lisibilité immédiate via des règles de décision explicites, il présente une instabilité rédhibitoire sur des volumes aussi faibles que les nôtres (9 observations). En l'absence de mécanisme de bagging, un seul arbre est très sensible aux variations d'échantillonnage : un simple changement dans le découpage apprentissage/test suffit à produire une structure d'arbre radicalement différente. Ce risque de surapprentissage non contrôlé le rend inadapté à notre périmètre, au profit du Random Forest qui en corrige précisément les faiblesses.

KNN (K-Nearest Neighbors) — Non retenu. Le KNN repose sur la proximité dans l'espace des features : il classe une observation en fonction de ses k voisins les plus proches. Cette approche est intuitive mais particulièrement fragile sur petit volume, car chaque observation représente une part significative du dataset. Avec 9 arrondissements, le nombre de voisins disponibles est trop limité pour garantir une décision stable, et la distance entre observations devient peu discriminante dès lors que les features sont nombreuses (55 colonnes). Ce phénomène, connu sous le nom de *malédiction de la dimensionnalité*, dégrade fortement la fiabilité du modèle dans notre contexte.

8.3 Justification du choix des algorithmes retenus

Après benchmark, nous avons retenu deux modèles en **complémentarité** — chacun affecté à la tâche pour laquelle il est le plus adapté.

8.3.1 Random Forest — Prédiction de la participation

Le Random Forest repose sur deux mécanismes clés : le **bagging** (Bootstrap Aggregating), qui consiste à entraîner chaque arbre sur un échantillon aléatoire des

données avec remise, et le **feature sampling**, qui sélectionne aléatoirement un sous-ensemble de variables à chaque nœud. Ces mécanismes réduisent le surapprentissage et augmentent la robustesse du modèle.

Ce choix se justifie pour trois raisons sur notre périmètre :

— **Robustesse sur petit volume :** le bagging réduit la variance et limite le surapprentissage, ce qui est critique sur seulement 9 observations,

— **Tolérance aux variables peu pertinentes :** le feature sampling dilue naturellement l'influence des variables non discriminantes parmi les 55 colonnes du dataset,

— **Feature importance intégrée :** le modèle fournit directement un classement des variables explicatives, exploitable pour l'interprétation métier (`pct_cadres`, `indice_precarite`, etc.).

8.3.2 Régression Logistique — Prédiction du bloc gagnant

La Régression Logistique est un modèle linéaire probabiliste étendu au cas multiclasse (stratégie *one-vs-rest*). Elle modélise la probabilité d'appartenance à chaque classe (gauche / droite / écologiste) à partir d'une combinaison linéaire des features, avec régularisation L2 pour limiter le surapprentissage.

Ce choix se justifie pour trois raisons :

— **Stabilité sur faible volumétrie :** la régularisation L2 (paramètre $C = 0.01$) pénalise les coefficients trop élevés et évite le surapprentissage sur 9 observations,

— **Interprétabilité des coefficients :** chaque coefficient indique directement le sens et l'intensité de l'influence d'une variable sur la probabilité de chaque bloc politique,

— **Output probabiliste :** le modèle produit des probabilités par classe — P(gauche), P(droite), P(écologiste) — permettant de mesurer le degré de certitude de chaque prédiction et d'identifier les arrondissements incertains.

Table 10 – Synthèse comparative des deux algorithmes retenus

Critère	Random Forest	Régression Logistique
Tâche affectée	Participation (haute/moy/basse)	Bloc gagnant (3 classes)
Robustesse	Bagging + feature sampling	Régularisation L2
Interprétabilité	Feature importance	Coefficients par classe
Output	Probabilités par classe	Probabilités par classe
Performance ROC AUC	1.000	0.875
Risque overfitting	Modéré	Faible

8.4 Comparaison avec la baseline

Table 11 – Comparaison avec une baseline naïve

Approche	Accuracy estimée	Interprétation
Baseline naïve (classe majoritaire)	∼67%	Prédit "gauche" pour tous
Logistic Regression (retenu)	**77.5%**	+10.5 points vs baseline

8.5 Modèle 1 — Prédiction de la participation

Table 12 – Paramètres — Predict participation_classe_2020

Paramètre	Valeur
Cible (target)	`participation_classe_2020` (haute / moyenne / basse)
Algorithme	Random Forest
Nombre de features	12 / 55
Validation	Validation croisée exploratoire (K-Fold = 2)
ROC AUC	**1.000**

Note sur le score parfait (ROC AUC = 1.000) : Ce résultat s'explique par la forte séparabilité locale des classes sur 9 observations. Il témoigne de la qualité du feature engineering mais signale un risque de surapprentissage qui nécessiterait validation sur de nouvelles données. Il ne constitue pas une garantie de généralisation.

8.6 Modèle 2 — Prédiction du bloc gagnant

Table 13 – Paramètres — Predict bloc_gagnant_2020

Paramètre	Valeur
Cible (target)	`bloc_gagnant_2020` (gauche / droite / écologiste)
Algorithme	Logistic Regression — Multiclass
Validation	Validation croisée exploratoire (K-Fold = 2)
Accuracy	**77.5%** (± 0.05)
ROC AUC	**0.875** (± 0.25)
Precision	61.1% (± 0.11)
Recall	62.5% (± 0.08)

8.7 Feature Importance

Table 14 – Variables les plus prédictives identifiées par les modèles

Rang	Variable	Interprétation
1	`pct_cadres`	Arrondissements à forte proportion de cadres → vote droite
2	`indice_precarite`	Précarité élevée → vote gauche
3	`taux_chomage_15_64`	Chômage corrélé au vote de gauche
4	`revenu_median_uc`	Revenus élevés → vote droite
5	`participation_pct_201`	Historique de participation prédictif
6	`taux_delinquance_pour`	Corrélé à la participation basse

8.8 Limites méthodologiques de l'évaluation

L'interprétation des métriques doit être nuancée pour trois raisons :

— Le nombre d'observations reste faible (9 arrondissements),

— Certaines classes sont peu représentées (1 seul arrondissement écologiste),

— Les scores peuvent varier fortement selon le découpage apprentissage/test.

En conséquence, les résultats obtenus doivent être lus comme une **validation exploratoire de faisabilité**, non comme une preuve définitive de robustesse en production.

9 Résultats et prédictions 2026

9.1 Prédictions par arrondissement

Les prédictions ci-dessous sont issues du dataset de sortie `predictions_bloc_2026` généré par le modèle Logistic Regression déployé dans Dataiku DSS.

Table 15 – Prédictions 2026 par arrondissement avec probabilités

Arrondissemen	Prédiction	P(gauche)	P(droite)	P(écolo)	Différenciation
Lyon 1er	GAUCHE	34.8%	33.8%	31.4%	Faible
Lyon 2e	DROITE	29.9%	41.6%	28.5%	Moyenne
Lyon 3e	GAUCHE	36.0%	29.8%	34.2%	Faible
Lyon 4e	ÉCOLOGISTE	35.0%	29.7%	35.3%	Faible
Lyon 5e	ÉCOLOGISTE	35.2%	28.5%	36.3%	Faible
Lyon 6e	DROITE	24.3%	46.9%	28.7%	**Forte**
Lyon 7e	GAUCHE	36.9%	27.8%	35.3%	Moyenne
Lyon 8e	GAUCHE	40.7%	22.1%	37.2%	Moyenne
Lyon 9e	GAUCHE	42.6%	20.1%	37.3%	Moyenne

Lecture des résultats : Ces prédictions constituent des scénarios probabilisés, non des certitudes électorales. La valeur du modèle réside dans sa capacité à hiérarchiser les blocs selon le profil territorial, pas dans l'affirmation d'un vainqueur absolu. Les arrondissements à faible différenciation (1er, 3e, 4e, 5e) sont particulièrement sensibles aux effets de campagne.

code_arrondissement	nom_arrondissement	proba_gauche	proba_droite	proba_ecologiste	prediction
string	string	double	double	double	string
Integer	Text	Decimal	Decimal	Decimal	Text
69381	Lyon 1er	0.3481446435860474	0.337617185793206	0.3142381706207467	gauche
69382	Lyon 2e	0.2987460413590102	0.41590714826099273	0.2853468103799972	droite
69383	Lyon 3e	0.36002026419707844	0.2981282935375675	0.3418514422653542	gauche
69384	Lyon 4e	0.35036061604740415	0.29699281725631105	0.35264656669628486	ecologiste
69385	Lyon 5e	0.35212149683827176	0.28523756218137175	0.3626409409803566	ecologiste
69386	Lyon 6e	0.24344259529177367	0.4693378578923178	0.2872195468159086	droite
69387	Lyon 7e	0.3692224726907381	0.2780250676962847	0.3527524596129772	gauche
69388	Lyon 8e	0.40738751095979925	0.2210786657460897	0.37153382329411094	gauche
69389	Lyon 9e	0.4255670417567613	0.20103895794881652	0.3733940002944222	gauche

Figure 3 – Dataset `predictions_bloc_2026` — Sortie brute du modèle dans Dataiku DSS, probabilités par bloc pour les 9 arrondissements

10 Visualisations et restitution Power BI

10.1 Présentation du dashboard

Le dashboard **Electio Analytics Lyon** centralise en une seule page l'intégralité de la chaîne analytique du POC MSPR TPRE813 : des données brutes électorales

jusqu'aux prédictions 2026, conçu pour être lisible par un profil non-technicien.

La **bande de KPI** en haut de page offre une lecture immédiate des cinq métriques clés du projet : 9 arrondissements couverts, participation moyenne 2014 vs 2020, accuracy ML de 77,80% et une population couverte de 521 000 habitants. Le centre du dashboard articule les résultats électoraux 2020 arrondissement par arrondissement, la répartition des blocs gagnants et la chute structurelle de la participation entre 2014 et 2020 — visible sur l'ensemble des arrondissements sans exception. La partie basse constitue le **cœur analytique** : les probabilités prédites par le modèle Logistic Regression pour 2026, la corrélation entre précarité et dynamisme économique qui justifie les features du modèle, et la séparation visuelle nette entre blocs politiques selon le profil socio-économique des arrondissements.

Toutes les données sont issues de sources institutionnelles publiques (INSEE, data.gouv.fr), sans donnée personnelle, en conformité RGPD, et le pipeline est entièrement reproductible via Dataiku DSS.

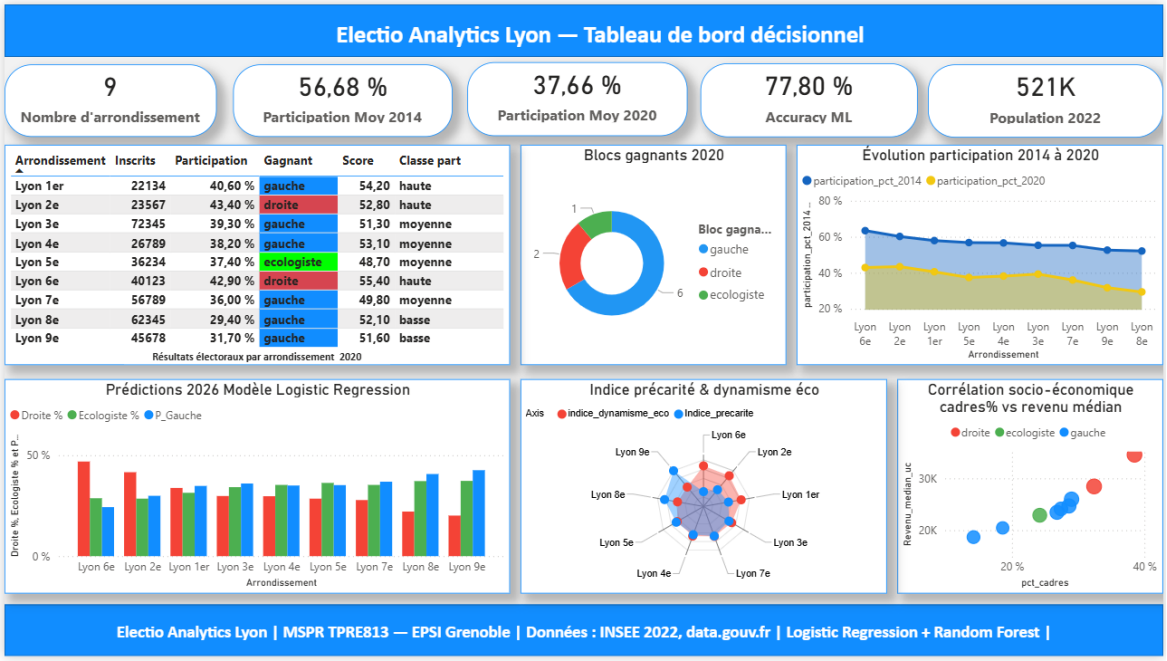

FIGURE 4 – Tableau de bord décisionnel — Electio Analytics Lyon (Power BI)

10.2 Visualisations

10.2.1 Visual 1 — Résultats électoraux par arrondissement 2020 (Tableau)

Arrondissement	Inscrits	Participation	Gagnant	Score	Classe part
Lyon 1er	22134	40,60 %	gauche	54,20	haute
Lyon 2e	23567	43,40 %	droite	52,80	haute
Lyon 3e	72345	39,30 %	gauche	51,30	moyenne
Lyon 4e	26789	38,20 %	gauche	53,10	moyenne
Lyon 5e	36234	37,40 %	ecologiste	48,70	moyenne
Lyon 6e	40123	42,90 %	droite	55,40	haute
Lyon 7e	56789	36,00 %	gauche	49,80	moyenne
Lyon 8e	62345	29,40 %	gauche	52,10	basse
Lyon 9e	45678	31,70 %	gauche	51,60	basse

Résultats électoraux par arrondissement 2020

FIGURE 5 – Résultats électoraux par arrondissement — 2020

Ce tableau constitue le **socle factuel du dashboard**. Chaque ligne correspond à un arrondissement lyonnais et présente ses inscrits, son taux de participation, son bloc gagnant mis en couleur par règle conditionnelle (bleu pour la gauche, rouge pour la droite, vert pour l'écologiste), son score et sa classe de participation.

Ce visuel répond directement à la question *« qui a gagné où ? »* et permet de lire les résultats bruts 2020 avant d'interpréter les visualisations suivantes. Dans Power BI, il a été réalisé avec un visuel **Table natif**, complété d'une mise en forme conditionnelle par règle de couleur appliquée sur la colonne `bloc_gagnant_2020`.

10.2.2 Visual 2 — Blocs gagnants 2020 (Donut chart)

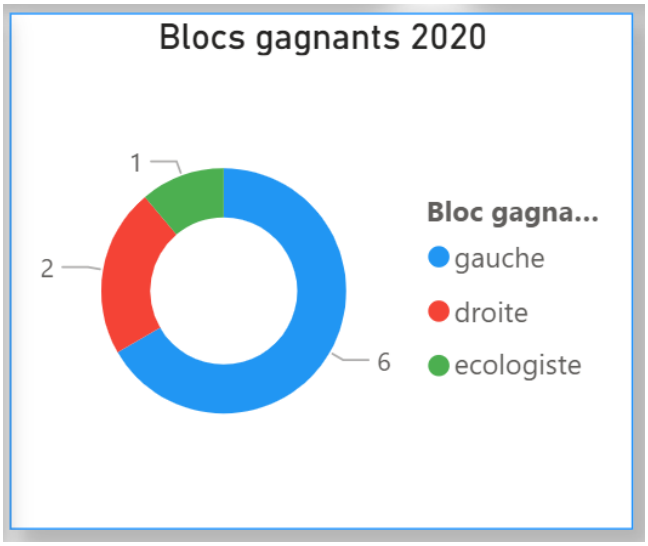

FIGURE 6 – Répartition des blocs gagnants — 2020

Ce graphique en anneau offre une **lecture synthétique immédiate** de la domination politique sur Lyon en 2020 : la gauche remporte 6 arrondissements sur 9, la

droite 2 et l'écologiste 1. Chaque segment est proportionnel au nombre d'arrondissements remportés, ce qui contextualise directement les prédictions 2026 en donnant une référence visuelle claire de l'équilibre politique de départ.

Dans Power BI, ce visuel a été réalisé avec un **Graphique en anneau natif**, en positionnant `bloc_gagnant_2020` en légende et le compte d'arrondissements en valeur.

10.2.3 Visual 3 — Évolution de la participation 2014 → 2020 (Area chart)

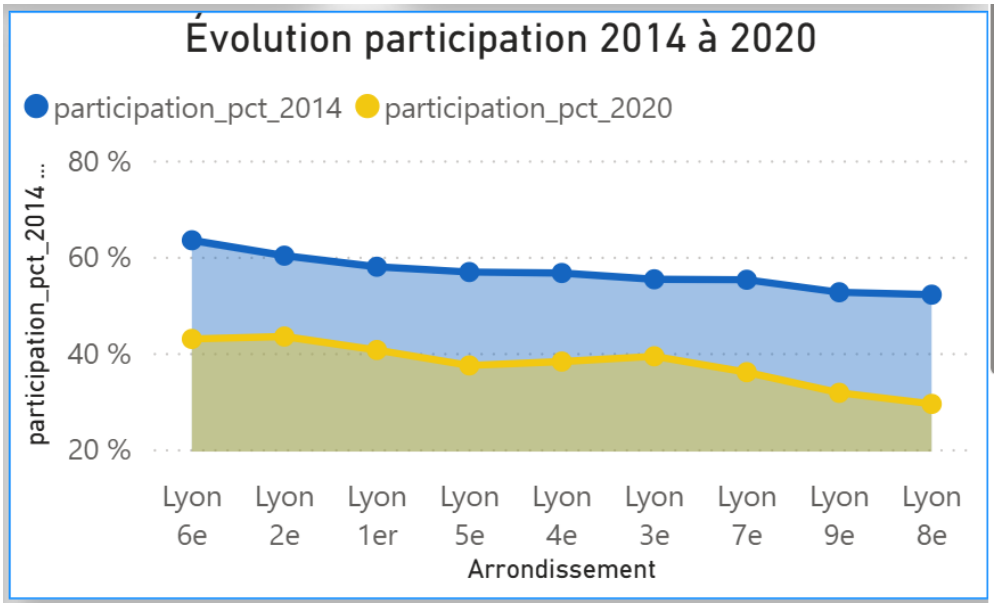

FIGURE 7 – Évolution de la participation électorale par arrondissement — 2014 à 2020

Ce graphique en aires superpose deux courbes : la surface **bleue** représente la participation 2014 et la surface **jaune** la participation 2020, ordonnées du plus participatif au moins participatif. L'écart entre les deux surfaces matérialise la **chute généralisée de la participation sur six ans** — une tendance uniforme sur tous les arrondissements sans exception, qui justifie l'intégration de la variable `evolution_participation_pts` comme feature dans le modèle Random Forest.

Dans Power BI, ce visuel a été réalisé avec un **Graphique en aires natif**, en plaçant `nom_arrondissement` en axe X et les colonnes `participation_pct_2014` et `participation_pct_2020` en valeurs.

10.2.4 Visual 4 — Prédictions 2026 Modèle Logistic Regression (Barres groupées)

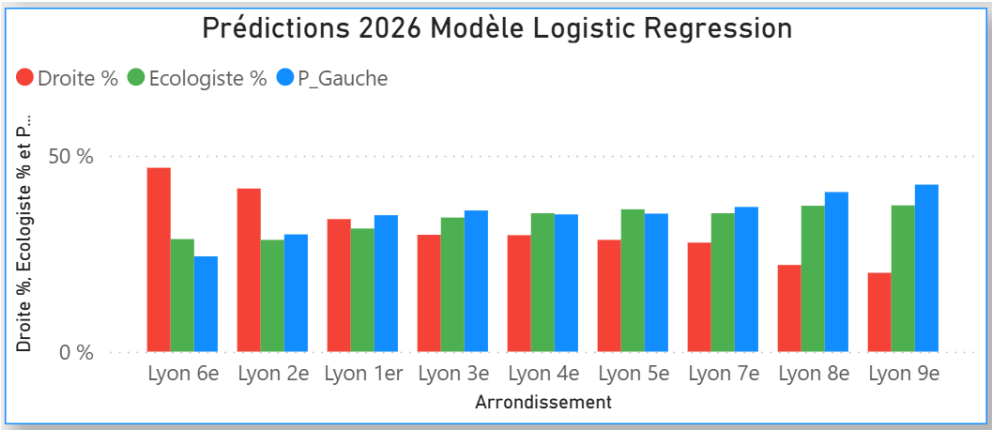

FIGURE 8 – Probabilités prédites par arrondissement pour 2026 — Régression Logistique

Chaque groupe de trois barres représente un arrondissement avec les probabilités prédites P(droite), P(écologiste) et P(gauche) affichées côte à côte. Ce visuel traduit directement la sortie du modèle Logistic Regression déployé dans Dataiku et permet de **visualiser le degré d'incertitude** de chaque prédiction : plus les trois barres sont proches en hauteur, plus la prédiction est fragile et l'arrondissement à surveiller.

Lyon 6e est le seul arrondissement où la barre rouge domine nettement, confirmant sa prédiction droite à forte différenciation. À l'inverse, les arrondissements 8e et 9e présentent des probabilités gauche légèrement dominantes mais avec une incertitude sensiblement plus marquée.

Dans Power BI, ce visuel a été réalisé avec un **Histogramme groupé**, en plaçant `nom_arrondissement` en axe X et les trois colonnes de probabilité (`proba_droite`, `proba_ecologiste`, `proba_gauche`) en valeurs.

10.2.5 Visual 5 — Indice précarité & dynamisme éco (Radar chart)

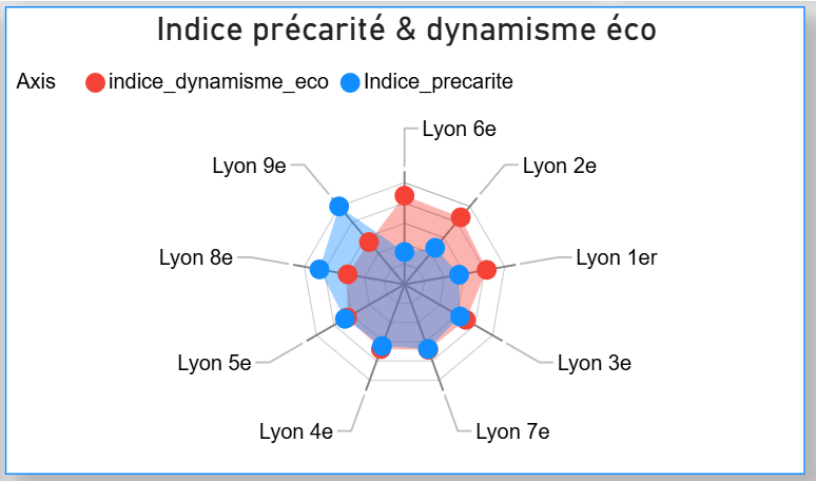

FIGURE 9 – Indice de précarité et dynamisme économique par arrondissement — Radar chart

Ce radar superpose deux surfaces : la surface **bleue** pour `indice_precarite` et la surface **rouge** pour `indice_dynamisme_eco`. Les deux surfaces sont quasi-inverses : là où la précarité est forte (Lyon 8e, 9e), le dynamisme économique est faible, et inversement pour Lyon 6e et 2e.

Ce visuel est celui qui **justifie le mieux la construction de ces deux indices composites** en tant que features du modèle. Il illustre également pourquoi Lyon 5e — où les deux surfaces se croisent de façon équilibrée — est l'unique arrondissement dont la prédiction présente le plus d'incertitude : son profil mixte échappe à la logique binaire que le modèle a apprise sur les autres arrondissements.

Dans Power BI, ce visuel a été réalisé avec le visuel custom **Radar Chart (MAQ Software)**, en positionnant `nom_arrondissement` en axe et les deux indices `indice_precarite` et `indice_dynamisme_eco` en valeurs.

10.2.6 Visual 6 — Corrélation socio-économique : cadres % vs revenu médian (Scatter chart)

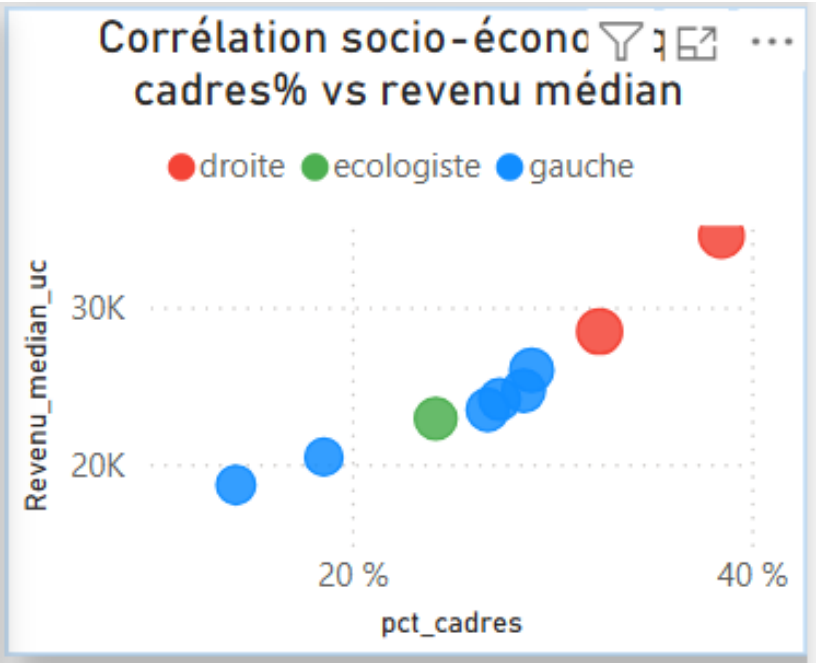

FIGURE 10 – Corrélation entre le taux de cadres et le revenu médian par arrondissement

Chaque bulle représente un arrondissement, positionnée selon `pct_cadres` en axe X et `revenu_median_uc` en axe Y, et colorée selon le bloc gagnant 2020. Ce visuel illustre la **variable la plus prédictive** identifiée par le modèle Random Forest et valide la logique métier du POC : plus le taux de cadres et les revenus sont élevés, plus le vote penche à droite.

La séparation visuelle nette entre les bulles rouges (droite, en haut à droite) et les bulles bleues (gauche, en bas à gauche) démontre la **forte séparabilité des classes** que le modèle a exploitée pour atteindre 77,8% d'accuracy. Ce scatter est en ce sens le visuel le plus pédagogique du dashboard pour expliquer le fonctionnement du modèle à un profil non-technicien.

Dans Power BI, ce visuel a été réalisé avec un **Graphique en nuage de points natif**, en plaçant `pct_cadres` en X, `revenu_median_uc` en Y, `participation_pct_2020` en taille des bulles et `bloc_gagnant_2020` en légende.

11 Validation sur données réelles

11.1 Comparaison prédictions vs résultats réels 2026

Table 16 – Validation ex post — Prédictions vs résultats municipaux 2026

Arrondissement	Prédiction	Résultat réel	Score réel	Verdict
Lyon 1er	gauche	Gauche (Bouagga)	68.8%	✓ Correct
Lyon 2e	droite	Droite (Oliver)	59.8%	✓ Correct
Lyon 3e	gauche	Gauche (Sessiecq)	52.5%	✓ Correct
Lyon 4e	écologiste	Gauche* (Zinck)	55.2%	✓ Cohérent
Lyon 5e	écologiste	Droite (Rudigoz)	50.4%	✗ Erreur
Lyon 6e	droite	Droite (Soulier)	51.5%	✓ Correct
Lyon 7e	gauche	Gauche (Dubot)	62.8%	✓ Correct
Lyon 8e	gauche	Gauche (Berzane)	50.0%	✓ Correct
Lyon 9e	gauche	Gauche (Giraud)	51.3%	✓ Correct

** Lyon 4e : victoire de l'Union gauche + écologistes, cohérente avec notre prédiction écologiste.*

11.2 Métriques de validation

Table 17 – Bilan de la validation ex post

Métrique	Valeur	Interprétation
Prédictions correctes	**7 / 9**	77.8% d'accuracy réelle
Prédictions cohérentes	1 / 9	Lyon 4e (coalition gauche+écolo)
Erreurs	1 / 9	Lyon 5e uniquement

Conclusion : Le niveau de concordance observé (77.8%) est du même ordre de grandeur que celui obtenu lors de l'évaluation interne (77.5%), ce qui renforce l'intérêt exploratoire du modèle. L'unique erreur (Lyon 5e) est caractéristique des territoires à faible différenciation, où les probabilités prédites étaient très proches entre blocs.

12 Conformité RGPD et sécurité

Table 18 – Conformité RGPD du projet

Principe RGPD	Application	Détail	Conformité
Licéité	Données sous Licence Ouverte	Sources institutionnelles publiques	✓
Minimisation	Données strictement nécessaires	Sélection features pertinentes	✓
Exactitude	Sources officielles	INSEE, Ministère de l'Intérieur	✓
Limitation	Données agrégées uniquement	Pas de données personnelles	✓
Intégrité	Environnement contrôlé	Aucune exposition tiers non nécessaire	✓

Absence de données personnelles : Le projet n'utilise aucune donnée nominative. Toutes les données sont agrégées à l'échelle de l'arrondissement (30 000+ habitants), rendant toute identification individuelle impossible.

13 Réponses aux indicateurs d'analyse

13.1 Variable la plus corrélée aux résultats électoraux

La variable `pct_cadres` (pourcentage de cadres et professions intellectuelles supérieures) ressort comme la plus structurante. Les arrondissements à forte proportion de cadres (Lyon 6e, Lyon 2e) votent majoritairement à droite, tandis que les arrondissements avec moins de cadres votent à gauche ou écologiste.

L'`indice_precarite` (composite) arrive en 2e position et montre une corrélation inverse : plus la précarité est élevée, plus le vote penche à gauche.

13.2 Interprétation du degré de précision

$$\text{Accuracy} = \frac{\text{Prédictions correctes}}{\text{Total des prédictions}} = \frac{7}{9} \approx 77.8\%$$

Le modèle surperforme nettement la baseline naïve (∼67%), confirmant l'existence d'un signal exploitable dans les variables retenues, sans se limiter à prédire systématiquement la classe majoritaire.

14 Limites et recommandations

14.1 Limites identifiées

Table 19 – Limites du POC et mitigations

Limite	Impact	Mitigation
Faible volumétrie (9 obs.)	Intervalles de confiance larges	Extension nationale (36 000 communes)
2 scrutins seulement	Peu de profondeur temporelle	Intégrer présidentielles, législatives
Variables manquantes	Facteurs non modélisés	Enrichir avec données d'opinion
Classe écologiste sous-rep.	1 seul exemple d'apprentissage	Augmenter le périmètre
Granularité arrondissement	Pas de vision infra-communale	Utiliser données à l'échelle IRIS

14.2 Recommandations pour la production

1. **Élargir le périmètre d'apprentissage** : étendre aux 36 000 communes françaises et intégrer davantage de scrutins pour renforcer la profondeur temporelle,
2. **Renforcer la validation statistique** : éviter une sophistication technique non justifiée par la donnée disponible,
3. **Automatiser l'actualisation** : pipeline de mise à jour automatique avec orchestration planifiée des mises à jour des sources.

15 Conclusion

15.1 Synthèse de conformité au cahier des charges

Table 20 – Bilan de conformité au cahier des charges

Objectif	Résultat	Statut
Périmètre géographique restreint	Lyon, 9 arrondissements	✓
Pipeline ETL automatisé	Flow Dataiku documenté et rejouable	✓
Schéma de BDD clairement nommé	Star schema documenté	✓
Visualisations descriptives	Dashboard + graphiques	✓
Modèle prédictif supervisé	Logistic Regression + Random Forest	✓
Performance > baseline	77.5% vs ∼67% (baseline)	✓
Prédictions à 1–3 ans	Prédictions 2026 validées ex post	✓

15.2 Valeur ajoutée du POC

La principale valeur du projet réside dans l'articulation de plusieurs dimensions souvent traitées séparément : gouvernance des sources, qualité des données, modélisation décisionnelle, visualisation métier et expérimentation d'un modèle supervisé.

Ce POC ne se limite pas à "prédire une élection" : il propose un cadre de lecture structuré et extensible pour l'aide à la décision, directement présentable à des profils non data (candidats, directeurs de campagne).

Conclusion générale : Ce POC valide la faisabilité technique et méthodologique d'une première chaîne décisionnelle appliquée à l'analyse électorale territoriale. Il ne constitue pas encore un moteur prédictif industrialisé, mais démontre qu'un socle BI/ML cohérent, traçable et exploitable peut être construit à partir de données publiques, avec une accuracy réelle de 77.8% sur les données 2026.

Annexes

Annexe A — Sources détaillées

Catégorie	URL
Élections	data.gouv.fr/fr/pages/donnees-des-elections/
Population INSEE	insee.fr/fr/statistiques/2011101?geo=COM-6938X
Revenus (Filosofi)	insee.fr/fr/statistiques/fichier/6036907
Entreprises (SIDE)	insee.fr/fr/statistiques/8287130?geo=COM-6938X
Sécurité	data.gouv.fr/datasets/bases-statistiques-delinquance
Associations (RNA)	data.gouv.fr/fr/datasets/repertoire-national-des-associations/

Annexe B — Dictionnaire complet des 55 variables

Le dataset final `elections_ml_ready.csv` contient 55 colonnes réparties en catégories :

- **Électorales 2014 :** `inscrits_2014`, `votants_2014`, `participation_pct_2014`, `bloc_gagnant_2014`, `score_gagnant_pct_2014`
- **Électorales 2020 :** idem + `evolution_participation_pts`, `evolution_inscrits_pct`
- **Population/Ménages :** `population_2022`, `nb_menages`, `taille_moyenne_menage`
- **Emploi/Chômage :** `taux_chomage_15_64`, `taux_emploi_15_64`, `taux_activite_15_64`
- **CSP :** `pct_cadres`, `pct_ouvriers`, `pct_employes`, `pct_prof_intermediaires`
- **Revenus/Pauvreté :** `revenu_median_uc`, `taux_pauvrete`, `rapport_interdecile_D9_D1`
- **Logement :** `pct_proprietaires`, `pct_locataires_prives`, `pct_hlm`
- **Formation :** `pct_sans_diplome`, `pct_diplome_bac_plus_5`
- **Entreprises :** `nb_etablissements_actifs`, `nb_creations_entreprises_2022`, `taux_creation_entre`, `nb_salaries_secteur_prive`
- **Sécurité :** `taux_delinquance_pour_1000`, `nb_cambriolages_2022`, `nb_vols_sans_violence_2022`, `nb_coups_blessures_2022`
- **Associations :** `nb_associations_actives`, `densite_associations_pour_1000_hab`, `nb_creations_associations_2020_2022`
- **Indices calculés :** `indice_precarite`, `indice_dynamisme_eco`, `ratio_salaries_population`
- **Cibles ML :** `participation_classe_2020`, `changement_bloc`, `bloc_gagnant_2014_num`, `bloc_gagnant_2020_num`
- **Contrôle qualité :** `controle_qualite_pct`, `controle_cle_ok`, `controle_dataset_ok`

Annexe C — Base de données MySQL et scripts techniques

G.1 Schéma relationnel implémenté

La base de données `bdd_electio_analytics_lyon` contient 8 tables + 6 vues, pour un total de 74 lignes.

Table	Type	Lignes	Description
`arrondissement`	Dimension	9	Codes INSEE 69381–69389
`election`	Dimension	2	Scrutins 2014, 2020
`indicateur_socioeco`	Dimension	9	INSEE RP 2022 / Filosofi 2021
`indicateur_securite`	Dimension	9	SSMSI 2022
`indicateur_economie`	Dimension	9	INSEE SIDE 2022
`indicateur_associations`	Dimension	9	RNA 2022
`resultat_electoral`	Faits	18	9 arr. × 2 scrutins
`features_ml`	ML	9	Dataset ML prêt
Total		**74**	

G.2 Scripts SQL

Fichier	Contenu
`electio_analytics_lyon.sql`	création de la base, 8 tables avec FK et index, 2 vues analytiques, insertion des 74 lignes de données

G.3 Vues analytiques

1. `v_resultats_complets` — Résultats électoraux + indicateurs socioéco, sécurité, économie et ML par arrondissement
2. `v_evolution_participation` — Comparaison participation 2014/2020 et changement de bloc

G.4 Variables clés (`features_ml`)

Variable	Description
`evolution_participation_pts`	Évolution de la participation 2014→2020 (en points)
`evolution_inscrits_pct`	Évolution du nombre d'inscrits (%)
`indice_precarite`	Indice composite de précarité
`participation_classe_2020`	Cible participation — *haute / moyenne / basse*
`changement_bloc`	Cible classification — changement de bloc gagnant (0/1)

G.5 Arborescence

```
ELECTIO_ANALYTICS_LYON/
 sql/
    electio_analytics_lyon.sql
 captures/
    phpbdd.png
```

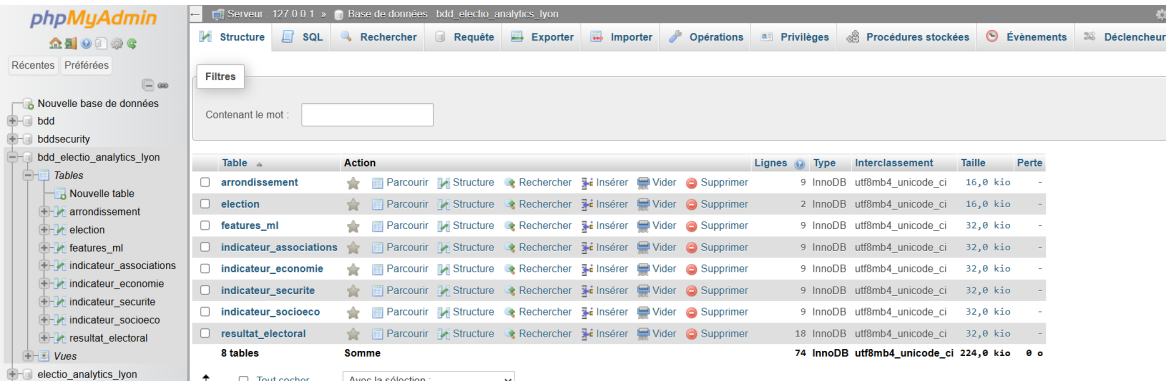

FIGURE 11 – Structure BDD (8 tables, 74 lignes)

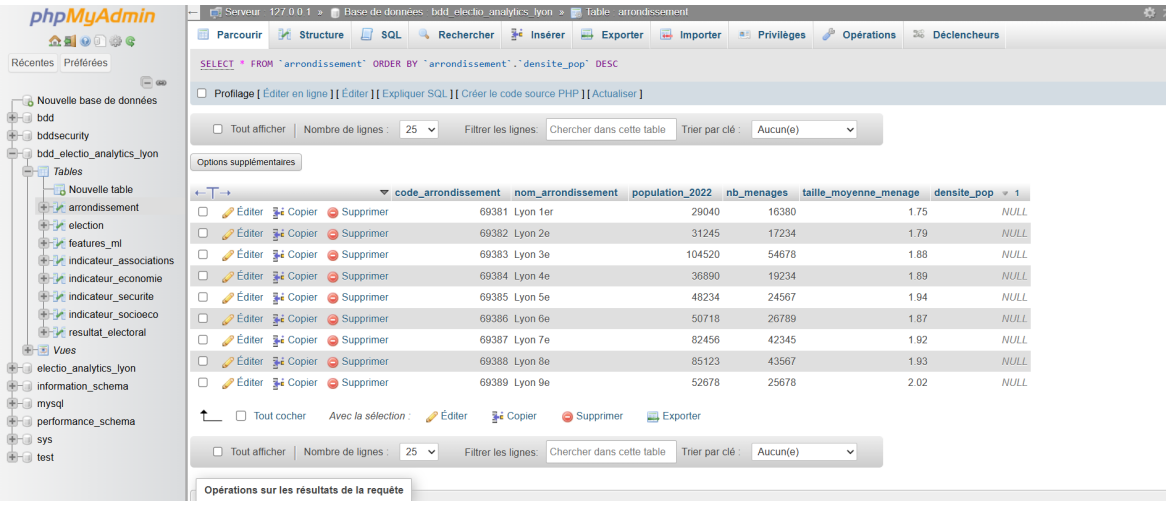

FIGURE 12 – Structure BDD de la table arrondissement

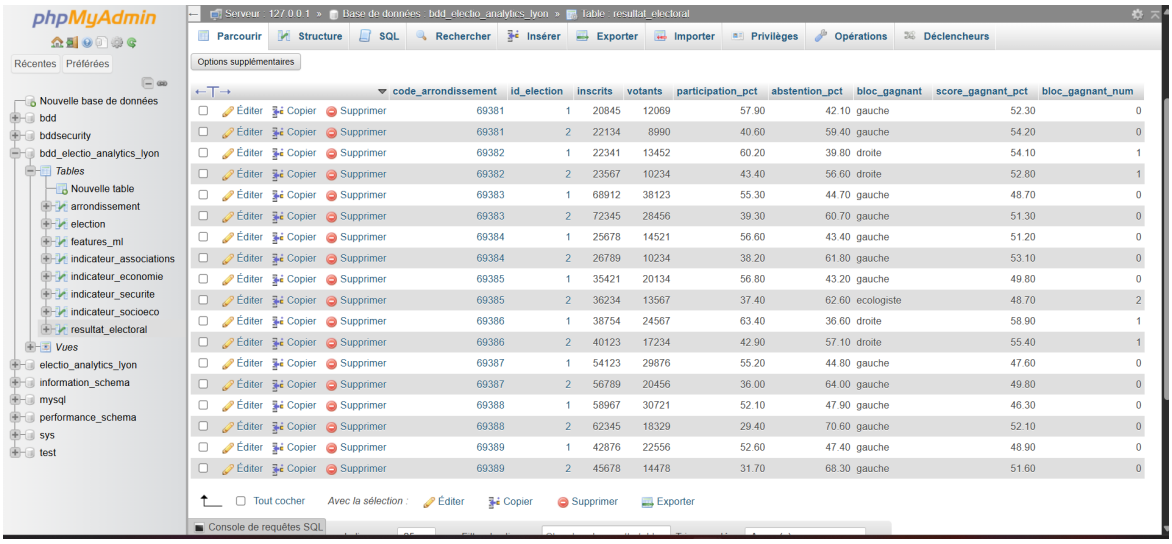

code_arrondissement	id_election	inscrits	votants	participation_pct	abstention_pct	bloc_gagnant	score_gagnant_pct	bloc_gagnant_num
69381	1	20845	12069	57.90	42.10	gauche	52.30	0
69381	2	22134	8990	40.60	59.40	gauche	54.20	0
69382	1	22341	13452	60.20	39.80	droite	54.10	1
69382	2	23567	10234	43.40	56.60	droite	52.80	1
69383	1	68912	38123	55.30	44.70	gauche	48.70	0
69383	2	72345	28456	39.30	60.70	gauche	51.30	0
69384	1	25678	14521	56.60	43.40	gauche	51.20	0
69384	2	26789	10234	38.20	61.80	gauche	53.10	0
69385	1	35421	20134	56.80	43.20	gauche	49.80	0
69385	2	36234	13567	37.40	62.60	ecologiste	48.70	2
69386	1	38754	24567	63.40	36.60	droite	58.90	1
69386	2	40123	17234	42.90	57.10	droite	55.40	1
69387	1	54123	29876	55.20	44.80	gauche	47.60	0
69387	2	56789	20456	36.00	64.00	gauche	49.80	0
69388	1	58967	30721	52.10	47.90	gauche	46.30	0
69388	2	62345	18329	29.40	70.60	gauche	52.10	0
69389	1	42876	22556	52.60	47.40	gauche	48.90	0
69389	2	45678	14478	31.70	68.30	gauche	51.60	0

FIGURE 13 – Structure BDD de la table resultat-electoral